

# **ПРОЕКТ**

**по Основам интеллектуального анализа данных и  
машинного обучения**

**НА ТЕМУ:**

**Моделирование климатических данных Индии с  
использованием линейной и логистической регрессии**

Выполнили студенты 3 курса:  
Романюк Дмитрий, Омирзаков Азамат

## 1. Цель работы

Цель проекта — исследовать задачи регрессии и бинарной классификации на реальном климатическом датасете по городам Индии 2024–2025 годов, реализовав линейную и логистическую регрессию с нуля на `numpy` и сравнив их качество с моделью Random Forest. В отчёте анализируется сходимость градиентного спуска, влияние гиперпараметров (`learning rate`, число эпох, размер батча) и качество классификации по основным метрикам.

## 2. Датасет: источник и описание

Происхождение данных.

Используется открытый датасет *Indian Climate Dataset 2024–2025*, размещённый на Kaggle:

источник — Kaggle, автор Ankush Narwade;

ссылка: <https://www.kaggle.com/datasets/ankushnarwade/indian-climate-dataset-20242025>

Краткое описание полей (главные колонки):

- `Date` — дата наблюдения.
- `City` — город (Mumbai, Delhi, Bengaluru и др.).
- `State` — штат Индии.
- `TemperatureMax C` — максимальная температура за сутки, °C.
- `TemperatureMin C` — минимальная температура за сутки, °C.
- `TemperatureAvg C` — средняя температура за сутки, °C (целевой признак для регрессии).
- `Humidity` — средняя относительная влажность, %.
- `Rainfall mm` — количество осадков, мм.
- `WindSpeed kmh` — средняя скорость ветра, км/ч.
- `AQI` — индекс качества воздуха.
- `AQICategory` — категориальное качество воздуха (Good, Satisfactory, Moderate, Poor, Very Poor).
- `Pressure hPa` — атмосферное давление, гПа.
- `CloudCover` — облачность, %.

В выборке более 7000 строк, что удовлетворяет требованию минимум 1500–2000 наблюдений и не менее 5 информативных признаков.

## 3. Метод и архитектуры моделей

### 3.1. Подготовка данных

- Удалены дубликаты, проверено отсутствие пропусков.
- Для моделей регрессии и классификации использовались числовые признаки:

`TemperatureMax C, TemperatureMin C, Humidity, Rainfall mm, WindSpeed kmh, AQI, Pressure hPa, CloudCover.`

- Признаки нормализованы по формуле Z-score: 
$$x'_j = \frac{x_j - \mu_j}{\sigma_j}$$
- Для всех моделей данные разделены на обучающую и тестовую выборки в пропорции 80/20 с предварительным перемешиванием.
- Для моделей, реализованных с нуля, к матрице признаков добавлен bias-столбец единиц.

### 3.2. Линейная регрессия (регрессия температуры)

Модель. Линейная регрессия для предсказания средней температуры:

$$\hat{y} = w_0 + w_1x_1 + \dots + w_nx_n = \mathbf{w}^T \mathbf{x}$$

Функция потерь (MSE):

$$J(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

Градиент MSE:

$$\nabla J(\mathbf{w}) = \frac{2}{m} \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y})$$

Обучение (mini-batch SGD):

- размер батча  $B$ ;
- на каждом шаге веса обновляются по правилу:

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \nabla J(\mathbf{w})$$

где:  $\eta$  — скорость обучения (learning rate).

Метрики: MSE, RMSE, MAE на train и test.

### 3.3. Логистическая регрессия (бинарная классификация)

Постановка.

Введена бинарная целевая переменная:

- $y=1$ , если `TemperatureAvg C` выше медианы по выборке — «жаркий день»;
- $y=0$  иначе — «не жаркий день».

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Сигмоида:

$$\hat{y} = \sigma(\mathbf{w}^T \mathbf{x})$$

Модель вероятности класса 1:

Логистическая функция потерь (кросс-энтропия):

$$J(\mathbf{w}) = -\frac{1}{m} \sum_{i=1}^m [y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)]$$

$$\nabla J(\mathbf{w}) = \frac{1}{m} \mathbf{X}^T (\hat{\mathbf{y}} - \mathbf{y})$$

Градиент лог-лосса:

$$J_\lambda(\mathbf{w}) = J(\mathbf{w}) + \frac{\lambda}{2m} \sum_{j=1}^n w_j^2$$

L2-регуляризация (опционально):

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \left( \frac{1}{B} \mathbf{X}_B^T (\hat{\mathbf{y}}_B - \mathbf{y}_B) + \frac{\lambda}{B} \mathbf{w} \right)$$

Обучение (mini-batch SGD):

(без штрафа для  $w_0$ ).

Метрики: accuracy, precision, recall, F1-score, confusion matrix, ROC AUC (по вероятностям).

### 3.4. Random Forest (вторая модель классификации)

В качестве второй модели классификации выбран Random Forest (реализация `RandomForestClassifier` из `scikit-learn`).

- Модель строит множество деревьев решений, каждое обучается на случайном подмножестве объектов и признаков.
- Предсказание — голосование деревьев (класс, набравший большинство).
- Используются те же признаки и разбиение train/test, что и для логистической регрессии.
- Метрики: accuracy, precision, recall, F1-score, confusion matrix, ROC AUC.

## 4. Гиперпараметры и эксперименты

### 4.1. Гиперпараметры регрессионных моделей

Для линейной и логистической регрессии задаются:

- learning rate  $\eta$  (например, 0.001, 0.01, 0.1);
- число эпох  $n\_epochs$ ;
- размер батча  $batch\_size$ ;
- коэффициент L2-регуляризации  $\lambda$  (при необходимости).

Проводился эксперимент: изменение одного параметра при фиксированных остальных и анализ графика сходимости функции потерь.

Наблюдения, которые можно описать (подставь свои численные выводы):

- При слишком маленьком  $\eta$  loss убывает очень медленно.
- При умеренном  $\eta$  loss быстро падает и стабилизируется.
- При слишком большом  $\eta$  loss начинает колебаться или расти — градиентный спуск становится нестабильным.
- Увеличение числа эпох улучшает качество до определённого уровня, затем приводит к плато.
- Малый `batch_size` увеличивает шум градиента, но помогает выходить из локальных минимумов; большой батч даёт более гладкую, но дорогую по времени сходимость.

## 4.2. Гиперпараметры Random Forest

Основные параметры:

- число деревьев `n_estimators` (например, 100);
- максимальная глубина `max_depth` (ограниченная или `None`);
- `random_state` для воспроизводимости.

Можно кратко отметить, что увеличение числа деревьев улучшает устойчивость и качество до некоторого предела, но увеличивает время обучения.

## 5. Результаты

### 5.1. Линейная регрессия

Модель	MSE train	MSE test
Линейная регрессия	0.001254880230546737	0.0012693867392215184

ошибка на тестовой выборке мала , что подтверждает хорошую аппроксимацию средней температуры по набору признаков и отсутствие сильного переобучения.

### 5.2. Логистическая регрессия и Random Forest

Модель	Accuracy test	Precision	Recall	F1-score	ROC AUC
Логистическая регрессия	0.9965800273 597811	0.99590 1639344 262	0.997 26402 18878 249	0.99658 2365003 4177	0.999971 92908913 63
Random Forest	0.994528043 7756497	0.99588 4773662 5515	0.993 16005 47195 623	0.99452 0547945 2055	0.994528 04377564 97